

TD 4

Exercice 1 – Évaluation(s) de l'erreur

Q 1.1 Rappelez la fonction coût au sens des moindres carrés sur un problème d'apprentissage binaire. Proposer quelques exemples pour montrer que les échantillons correctement classés participent à la fonction coût.

Q 1.2 En faisant appel à vos connaissances sur le perceptron, proposez une nouvelle fonction coût ne pénalisant que les points mal classés.

Q 1.3 En imaginant une fonction f de complexité infinie (capable de modéliser n'importe quelle frontière de décision), tracez à la main la frontière de décision optimale au sens des coûts définis précédemment pour le deux problèmes jouets de la figure 1. Ces frontières sont-elles *intéressantes*? Quels problèmes se posent?




FIGURE 1 – Gaussiennes non séparables linéairement

Exercice 2 – Perceptron

Q 2.1 Soit $\mathbf{w} = (2, 1)$ le vecteur de poids d'une séparatrice linéaire. Dessinez cette séparatrice dans le plan. Précisez sur le dessin les quantités $\langle \mathbf{w}, \mathbf{x} \rangle$ par rapport à un exemple \mathbf{x} bien classé et mal classé. Que se passe-t-il pour le produit scalaire dans le cas d'un exemple mal classé avec la mise-à-jour $\mathbf{w} \leftarrow \mathbf{w} + y\mathbf{x}$?

Q 2.2 Comment sont les classifieurs suivants par rapport à celui de la question précédente : $w^1 = (1, 0.5)$, $w^2 = (200, 100)$, $w^3 = (-2, -1)$?

Q 2.3 Donner un perceptron qui permet de réaliser le AND logique entre les entrées x_1 et x_2 (positif si les deux sont à 1, négatif sinon) et un autre pour le OR logique.

Q 2.4 Montrez que l'algorithme du perceptron correspond à une descente de gradient. La solution est-elle unique?

Exercice 3 – Expressivité des séparateurs linéaires

On se place dans l'espace des séparateurs linéaires : $f(\mathbf{x}_i) = \sum_j x_{ij}w_j$.

Q 3.1 Quelle est la dimension du vecteur \mathbf{w} ? Rappeler l'écriture matricielle de $f(\mathbf{x}_i)$. Tracer approximativement les frontières optimales en utilisant un modèle linéaire basique sur la figure de l'exercice 1.

Q 3.2 Nous allons augmenter l'expressivité du modèle en étendant l'espace de représentation initial dans le cas 2D : $\mathbf{x} = [x_1, x_2]$. Soit la transformation ϕ suivante : $\phi(\mathbf{x}) = [x_1, x_2, x_1^2, x_2^2, x_1x_2]$, considérons le modèle linéaire $f(\mathbf{x}) = \sum_j \phi_j(\mathbf{x})w_j$.

- Quelle est la dimension du vecteur \mathbf{w} dans ce cas ?
- Retracer les frontières de décision optimales sur la figure en utilisant cette nouvelle représentation.
- Pouvons nous retrouver les frontières linéaires de la question précédente dans ce nouvel espace ? Dans l'affirmative, donner les coefficients w_j associés.

Q 3.3 Les frontières sont-elles plus *intéressantes* en utilisant la première ou la seconde représentation des données ? Pouvez vous comparer grossièrement l'amplitude de la fonction coût (au sens des moindres carrés par exemple) dans les cas linéaires et quadratiques ? Qu'en déduire ? Sur quel élément vous basez vous pour mesurer la qualité du modèle créé ?

Q 3.4 Afin d'augmenter l'expressivité de notre classe de séparateur, nous nous tournons vers les représentations gaussiennes. Nous créons une grille de points $\mathbf{p}^{i,j}$ sur l'espace 2d, puis nous mesurons la similarité gaussienne du point \mathbf{x} par rapport à chaque point de la grille : $\phi(\mathbf{x}, \mathbf{p}^{i,j}) = Ke^{-\frac{\|\mathbf{x}-\mathbf{p}^{i,j}\|^2}{\sigma}}$. La nouvelle représentation de l'exemple est le vecteur contenant pour chaque dimension la similarité de l'exemple à un point de la grille.

- Quelle est la dimension du vecteur \mathbf{w} ?
- Donnez l'expression littérale de la fonction de décision.
- Quelle est la différence avec l'algorithme des fenêtres de Parzen ?
- Quel rôle joue le paramètre σ ?

Q 3.5 Introduction (très) pragmatique aux noyaux¹

- Que se passe-t-il en dimension 3 si nous souhaitons conserver la résolution spatiale du maillage ?
- Afin de palier ce problème, nous proposons d'utiliser la base d'apprentissage à la place de la grille : les points servant de support à la projection seront ceux de l'ensemble d'apprentissage. Exprimer la forme littérale de la fonction de décision dans ce nouveau cadre. Quelle est la nouvelle dimension du paramètre \mathbf{w} ?
- Que se passe-t-il lorsque σ tend vers 0 ? vers l'infini ? A-t-on besoin de toutes les dimensions de w ou est-il possible de retrouver la même frontière de décision en limitant le nombre de données d'apprentissage ? A quoi cela correspond-il pour $\|\mathbf{w}\|$?

1. Attention, il ne s'agit pas des mêmes noyaux que ceux de convolution pour l'estimation de densité...