Implantation d'une machine virtuelle en C Cours de Compilation Avancée (4I504)

Benjamin Canou & Emmanuel Chailloux Université Pierre et Maire Curie

Année 2016/2017 - Semaine 3

Interprète de bytecode

Interprète de bytecode : boucle de base

Flux d'entrée : opcodes simples et valeurs. Plus courant dans les machines à registres.

```
Ex: [ NOP ; GOTO ; 0 ]
void run(int code[]) {
 int pc = 0;
 while (TRUE) {
    switch (code[pc]) {
     case NOP:
                                 // instruction suivante
       pc++:
       break;
     case GOTO:
       pc = code[pc + 1];  // aller à l'adresse qui suit
       break;
     /* ... */
```

Interprète de bytecode : boucle de base

Variante : arguments dans l'opcode, à décoder.

Plus courant dans les machines à registres.

```
Ex: [ NOP ; GOTO(0) ]
```

```
void run(int code∏) {
  int pc = 0;
  while (TRUE) {
    /* décodage */
    int op, arg0, arg1;
    decode (code[pc], &op, &arg0, &arg1);
    switch (op) {
      case NOP:
        pc++;
        break:
      case GOTO:
        pc = arg0;
        break:
      /* ... */
```

Interprète de bytecode : instructions

```
Exemple d'encodage : OPCODE(8) \mid A_1(12) \mid A_2(12)
```

Autre possibilité : arguments variables pour chaque opcode

Interprète de bytecode : pile

Pile préallouée, vérifications de taille.

```
void run(int code∏) {
  int pc = 0;
  /* pile dans un tableau pré-alloué */
  int stack = malloc (MAX * sizeof (int)):
  int sp = 0;
  while (TRUE) {
    switch (code[pc]) {
      case PUSHINT:
        stack[sp++] = code[pc + 1];
        if (sp > MAX) exit (1);
        pc += 2;
        break:
     /* ... */
```

Interprète de bytecode : registres

Table de registres.

Autre possibilité : variables (optimisées) pour certains registres.

```
void run(int code∏) {
  int pc = 0; /* program counter : indice de l'op en cours */
  /* tableau de registres */
  int regs[16];
  while (TRUE) {
    int op, a0, a1, a2;
    decode (code[pc],&op,&a0,&a1,&a2);
    switch (op) {
      case MOVE:
        regs[a2] = regs[a0] + regs[a1];
        pc++;
        break;
      /* · · · · */
```

Interprète de bytecode : branchements

On change seulement le pointeur de code. On n'utilise pas les branchement du langage hôte.

```
case BRA_EQ_INT:
  int a = stack[sp - 1];
  int b = stack[sp - 2];
  sp -= 2;
  if (a == b) {
    /* on change le pc pour le prochain tour */
    pc = code[pc + 1];
  } else {
    pc += 2;
  }
  break;
```

Interprète de bytecode : appels

Exemple avec machine à registres.

On ajoute une pile d'appels (frame stack).

Paramètres dans les registres, retour dans r_0 .

```
int regs[16];
int cstack[MAX][16]:
int csp = 0;
  case CALL:
    /* sauvegarde registres et pc */
    memcpy(&cstack[rsp][1], &regs[1], 15 * sizeof(int));
    cstack[rsp][0] = pc + 1;
    if (++rsp > MAX) exit (2);
    /* jump */
    pc = a0;
    break:
  case RETURN:
    /* resultat dans r0 */
    memcpy(&regs[1], &cstack[--rsp][1], 15 * sizeof(int));
    pc = cstack[rsp][0];
    break;
```

Une VM bas niveau pourrait laisser faire le compilateur.

Il faut un mécanisme d'inter-opérabilité.

- ▶ Pour effectuer les appels
- ▶ Pour convertir les valeurs entre les deux mondes
- ▶ Pour assurer la gestion mémoire

Exemple: JNI

```
char[] str = "TCHOU TCHOU";
jstring jstr = (*env)->NewStringUTF(env, str);
```

Sur un exemple :

- ► Machine à registres.
- ► Instruction d'appel : EXT_CALL(prim,nbargs).
- ▶ Passage de paramètres comme une procédure normale.

Il faut une table de primitives :

```
int print_int(int v);
int read_int(void);
int add(int a, int b);
/* ... */

typedef int (*) () prim;
prim prims [N] = {
  print_int,
  read_int,
  add,
  /* */
}
```

```
EXT_CALL:
  switch (a1 /* nb args */) {
  case 0 :
    r0 = prims[a0]();
    break;
  case 1:
    r0 = prims[a0](regs[0]);
    break:
  case 2 :
    r0 = prims[a0](regs[0], regs[1]);
    break:
  /* ... */
  pc++;
  break;
```

Représentation des données

Représentation uniforme

Nécessité de parcourir les valeurs :

- ► Fonctions primitives génériques : égalité, sérialisation, etc.
- Gestion mémoire (cf. cours prochain)
- Introspection, affichage générique, etc.

Solution logique : uniformiser la structure des valeurs

Question centrale: distinction entre

- ▶ Valeurs immédiates (entiers, caractères, etc.)
- Valeurs allouées (tableaux, structures, etc.)
- Différentes sortes de valeurs allouées.

En machine : un pointeur = un entier = un mot machine

Représentation non uniforme

Il faut trouver l'information de type ailleurs que dans la donnée :

- Méta données issues du compilateur (structure de la pile, etc.)
- Algorithmes ambigus (c'est peut-être un pointeur)
- ▶ Mélange : informations dans les blocs, pas dans les immédiats

Solution simple: tout est pointeur

Idée : valeurs immédiates stockées dans des valeurs allouées

```
typedef enum { BOOL_TAG, INT_TAG, PAIR_TAG } tag_t ;
struct value ;
typedef struct value {
  tag_t tag ;
  union {
    enum { FALSE, TRUE } as_bool ;
    int as_int ;
    struct value as_pair [2] ;
  } contents ;
} value_t ;
```

Solution plus avancées

Bit(s) discrimant(s):

- On mange un bit sur le mot machine pour discriminer entre entier et pointeur
- Éventuellement plus de bits pour plusieurs types d'immédiats
- On utilise un système de tags comme précédemment pour les valeurs allouées
- On limite l'étendue des immédiats

NaN boxing

- Les valeurs de base font 64 bits
- Les flottants sont stockés tels quels
- Les entiers et les pointeurs sont encodés dans l'espace des NaN
- ▶ On utilise 64 bits pour des immédiats de 32 bits
- ▶ On limite les pointeurs à 4 Go

Exemple: la machine d'OCaml (pour changer)

```
typedef intnat value;
typedef uintnat header_t;
typedef uintnat mlsize t;
typedef unsigned int tag_t;
                                       /* Actually, an unsigned char */
typedef uintnat color_t;
typedef uintnat mark t;
/* Longs vs blocks. */
#define Is_long(x) (((x) & 1) != 0)
#define Is_block(x) (((x) & 1) == 0)
/* Conversion macro names are always of the form "to_from". */
/* Example: Val long as in "Val from long" or "Val of long". */
#define Val long(x) (((intnat)(x) << 1) + 1)
#define Long_val(x) ((x) >> 1)
#define Max_long (((intnat)1 << (8 * sizeof(value) - 2)) - 1)
#define Min_long (-((intnat)1 << (8 * sizeof(value) - 2)))</pre>
#define Val_int(x) Val_long(x)
#define Int val(x) ((int) Long val(x))
#define Unsigned_long_val(x) ((uintnat)(x) >> 1)
#define Unsigned int val(x) ((int) Unsigned long val(x))
```

Exemple: la machine d'OCaml

UPMC

```
/* Structure of the header:
For 16-bit and 32-bit architectures:
    +----+
    | wosize | color | tag |
    +----+
bits 31 10 9 8 7 0
*/
#define Tag_hd(hd) ((tag_t) ((hd) & 0xFF))
#define Wosize_hd(hd) ((mlsize_t) ((hd) >> 10))
#define Hd_val(val) (((header_t *) (val)) [-1]) /* Also an 1-value. */
#define Hd_op(op) (Hd_val (op))
                                           /* Also an 1-value. */
#define Hd bp(bp) (Hd val (bp))
                                           /* Also an 1-value. */
#define Hp val(val) ((char *) (((header t *) (val)) - 1))
#define Hp_op(op) (Hp_val (op))
#define Hp_bp(bp) (Hp_val (bp))
#define Val_op(op) ((value) (op))
#define Val_hp(hp) ((value) (((header_t *) (hp)) + 1))
#define Op_hp(hp) ((value *) Val_hp (hp))
#define Bp_hp(hp) ((char *) Val_hp (hp))
```

- Master Informatique - Compilation Avancée (4I504) - année 2016/2017

20/52

Exemple: la machine d'OCaml

```
/* The lowest tag for blocks containing no value. */
#define No_scan_tag 251
/* Fields are numbered from 0. */
#define Field(x, i) (((value *)(x)) [i])
                                                  /* Also an 1-value. */
/* Special case of tuples of fields: closures */
#define Closure_tag 247
#define Code_val(val) (((code_t *) (val)) [0]) /* Also an 1-value. */
/* Booleans are integers 0 or 1 */
#define Val bool(x) Val int((x) != 0)
#define Bool val(x) Int val(x)
#define Val false Val int(0)
#define Val true Val int(1)
#define Val_not(x) (Val_false + Val_true - (x))
```

Machines virtuelles fonctionnelles

La ZAM: machine fonctionnelle stricte

Schéma dérivé de la machine de Krivine :

- ▶ Le corps d'une instruction commence par GRAB,
- comme les fonctions ont plusieurs arguments, le code ressemble en fait à : [GRAB; n_{args}; . . . ; RETURN]
- ▶ les arguments sont passés sur la pile par les instructions APPLY{1,2,3} + compteur extra_args
- ► GRAB applique la fonction (évaluation stricte) si elle trouve les arguments nécessaires, sinon, elle crée une fermeture.

La ZAM : application générale

Comment s'exécute le programme suivant ?

```
# open Printf;;
# let separe sep =
  let rec aux i str =
    if i < String.length str then (
      printf "%c%c" str.[i] sep ;
      aux (i + 1) str
  in
  aux 0;;
val separe : char -> string -> unit = <fun>
# separe ',';;
- : string -> unit = <fun>
# separe ',' "toto";;
t.o.t.o.
-: unit =()
```

Grâce à CLOSURE, APPLY, GRAB et RETURN

La ZAM: CLOSURE

```
Instruct(CLOSURE): {
   int nvars = *pc++;
   int i;
   if (nvars > 0) *--sp = accu;
   Alloc_small(accu, 1 + nvars, Closure_tag);
   Code_val(accu) = pc + *pc;
   pc++;
   for (i = 0; i < nvars; i++) Field(accu, i + 1) = sp[i];
   sp += nvars;
   Next;
}</pre>
```

La ZAM: APPLY

```
Instruct(APPLY2): {
    value arg1 = sp[0];
    value arg2 = sp[1];
    sp -= 3;
    sp[0] = arg1;
    sp[1] = arg2;
    sp[2] = (value)pc;
    sp[3] = env;
    sp[4] = Val_long(extra_args);
    pc = Code_val(accu);
    env = accu;
    extra_args = 1;
    goto check_stacks;
}
```

La ZAM: GRAB

```
Instruct(GRAB): {
      int required = *pc++;
      if (extra_args >= required) {
        extra_args -= required;
      } else {
        mlsize_t num_args, i;
        num_args = 1 + extra_args; /* arg1 + extra args */
        Alloc_small(accu, num_args + 2, Closure_tag);
        Field(accu, 1) = env:
        for (i = 0; i < num_args; i++) Field(accu, i + 2) = sp[i];
      Code val(accu) = pc - 3; /* Point to the preceding RESTART instr. */
        sp += num_args;
        pc = (code_t)(sp[0]);
        env = sp[1];
        extra_args = Long_val(sp[2]);
        sp += 3;
      Next;
```

RESTART effectue la copie environnement \rightarrow pile. Compilation : ...RESTART; [GRAB; n_{args} ; ...; RETURN] ...

UPMC - Master Informatique - Compilation Avancée (4I504) - année 2016/2017 - 27/52

La ZAM: RETURN

```
Instruct(RETURN): {
    sp += *pc++;
    if (extra_args > 0) {
        extra_args--;
        pc = Code_val(accu);
        env = accu;
    } else {
        pc = (code_t)(sp[0]);
        env = sp[1];
        extra_args = Long_val(sp[2]);
        sp += 3;
    }
    Next;
}
```