Évaluation

James Eagan < iames.eagan@telecom-paristech.fr>



Ce cours a été développé en partie par des membres des départements IHM de Georgia Tech et Télécom Paris Tech. La liste de contributeurs inclut Gregory Abowd, Al Badre, James Eagan, Jim Foley, Elizabeth Mynatt, del Pierce, Coli Potts, Orris Shaw, John Slasko, et Bruce Walker.

Ces matériaux peuvent être utilisés avec attribution pour des buts non-lucratifs.





Outline

Overview

Evaluation Prédictive

Conception d'une expérience

Participants, IRB & La Morale

Collecte de données

Analyse & interprétation de résultats

Pourquoi Evaluer ?

Suppose:

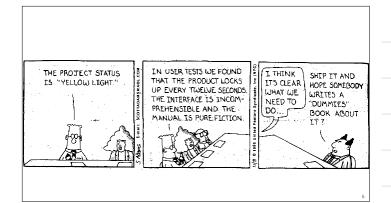
Utilisateurs et tâches identifiés

Besoins connus

Interface conçue, prototype construit

Mais ... est-ce que ça permettra à l'utilisateur d'exécuter ses tâches ? Est-ce mieux que la version précédente ?

, |



Genres d'Evaluation

Interprétative vs. Prédictive

Sommatative vs. Formative

Evaluation

Recueillir des données sur l'utilisabilité d'un design pour un groupe défini d'utilisateurs pour une activité définie dans un contexte défini

7

Buts

Evaluer la fonctionnalité du système

Evaluer l'effet de l'interface sur l'utilisateur

Identifier problèmes particuliers avec le système

8

Deux Genres

Evaluation Formative

Au début du projet, pendant sa duré de vie

Evaluation de la conception

Evaluation Sommative

Après la construction du système. Jugement finale.

Evaluation de l'implémentation

.

Approches

Expérimental

Dans le labo, environnement contrôlé

Plutôt quantitatif

Naturaliste

Observation dans un contexte réel

Plutôt qualitatif

Compromis

Experimental

- + Reproductibilité
- + Plus "objectif"
- Cher, besoin de vrais utilisateurs & labo
- Réaliste ?

Naturaliste

- + Validité écologique
- + Peu cher, rapide Pas reproductible, résultats particuliers aux utilisateurs
- Pas quantitative

Méthodes d'Evaluation

Expérimentales, Obsérvationelles

Typiquement avec utilisaeurs

Expériences à partir de spécification d'utilisatbilité

Prédictive

(sans utilisateur)

| Idée : | L'observation d'utilisateurs coûte cher, prend du temps | | Essayons de prédire l'utilisation plutôt que de l'observer | | Economiser ressources (rapide, coût réduit) |

Approche

Revues d'experts

Un pro de l'IHM (pas de vrais utilisateurs) interagisse avec le système, essaie de trouver de problèmes potentiels

Idéalement :

N'a pas encore utilisé d'autres prototypes

Connait bien le domaine ou la tâche

Comprend bien perspectives utilisateur

14

Méthodes de l'Evaluation Prédictive

Evaluation Heuristique

« Discount » tests d'utilisabilité

Cognitive Walkthrough (« passage à travers cognitif »)

Evaluation Heuristique

Développé par Jakob Nielsen (www.useit.com) Plusieurs experts d'utilisabilité évaluent le système selon des heuristiques simples et généraux



http://www.useit.com/papers/guerrilla_hci.html

Méthode

Déterminer les inputs

Evaluer le système

Collecte d'observations

Trie de sévérité

17

Déterminer Inputs

Qui sont les experts?

Apprendre le domaine, ses pratiques

Quel est le prototype à évaluer ?

Mock-ups, storyboards, ... ou bien un système qui tourne

		_
		_

Méthode d'évaluation

 Reviewers évaluent le système selon les heuristiques haut-niveau (principes d'utilisabilité)

Visibilité de l'état du système

Concordance entre le système et le monde extérieur

Contrôle & libérté pour l'utilisateur Standards & cohérence

Prévention d'erreurs

Reconnaissance plutôt que rappel

Flexibilité & efficacité d'usage

Design aesthétique & minimalist

Aider l'utilisateur à reconnaître, identifier & se rattraper face à une

erreur

Aide & documentation

[Jakob Nielsen, http://www.useit.com/papers/heuristic]

19

Méthode d'évaluation

 Reviewers évaluent le système selon les heuristiques haut-niveau (principes d'utilisabilité)

> Use simple and natural dialog Speak user's language Minimize memory load Be consistent Provide feedback Provide clearly-marked exits Provide shortcuts Provide good error messages Prevent errors

> > 20

Processus

Effectuer au moins deux itérations du système :

Regarder chaque écran

Le flot d'écran à écran

À chaque étape, évaluer selon les heuristiques

Chercher de problèmes :

Subjectif (si tu pense que ce l'est, ce l'est)

T'inquiète pas si c'est un vrai problème

Debriefing

Récolter tout problème identifié par les reviewers

Identifier quels sont ou ne sont pas de vrais problèmes

Grouper, structurer

Documenter et enregistrer les problèmes

22

Classer par Sévérité

Echelle de 0 à 4

4 est le plus sévère

Selon:

Fréquence

Impact

Persistance

Impact sur le marché

23

Avantages

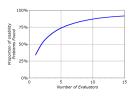
Peu cher, bon pour des PME qui ne peuvent pas payer plus

Trouver quelqu'un avec de l'expérience dans la méthode est l'idéale

Application

Selon Nielsen, 5 évaluations trouvent 75 % de problèmes

Au dessus, on en trouve plus, mais moins efficace



25

Problèmes

Evaluation très subjective

Dépend l'expertise des reviewers

Ces heuristiques, sont-elles les bonnes?

D'autres ont été proposées

Comment déterminer ce qui est un vrai problème d'utilisabilité

Quelques "problèmes" identifiés ne le sont pas

26

Discount Usability Testing

Hybride de tests d'utilisabilité empirique et de l'évaluation heuristique

Effectuer 2 ou 3 séances "penser à l'orale" avec un prototype (sur papier ou mock-up)

Mockups

Pas besoin que les mockups soient parfait

Plusieurs approches:

Doivent être rapide à créer, pas trop cher

Souvent des sketches

Limitations des papier : emphase sur éléments visuels

Parfois difficile à utiliser dans le test

28

Cognitive Walkthrough

Mesurer facilité d'apprentissage et d'utilisabilité en simulant comment un utilisateur explore et apprend le système

Une "expérience de pensée" d'utilisabilité

Comme "code walkthrough" dans la génie logiciel

Proposé par Polson, Lewis, et al à UC Boulder





29

CW Processus

Construire tâches conçues à partir de la spécification du système ou du mockup

Walk through (itérer sur) les activités nécessaires pour aller d'écran à écran

Examiner actions nécessaires pour chaque tâche, essayer de prédire comment un utilisateur fonctionnerait et quels problèmes il trouverait

Besoins

Description d'utilisateurs et leur contexte

Description de tâches

Liste complète d'actions exigées pour effectuer chaque tâche

Prototype ou description du système

31

Suppositions

L'utilisateur a déjà une idée brut quoi faire

L'utilisateur explore le système, en cherchant d'actions qui peuvent contribuer à effectuer sa tâche

L'utilisateur choisit l'action qui semble le mieux pour son but

L'utilisateur interprète les réponses et décide s'il est plus proche à son but

32

Méthode

Itérer sur séquence d'actions

Action 1

Réponse A, B, ...

Action 2

Réponse A

Pour chaque étape, poser *quatre questions* en essayant de construire une *histoire de croyance*

Questions

Est-ce que l'utilisateur essaye de produire l'effet associé à cette action ?

Est-ce qu'il sera capable de remarquer la bonne action ?

Un fois trouvée, saura-t-il qu'elle est la bonne action pour l'effet souhaité ?

Comprendra-t-il le feedback après l'avoir effectué ?

34

Répondre aux Questions

Est-ce que l'utilisateur essaye de produire l'effet associé à cette action ?

Evidence typique

Ça fait partie de leur tâche de base

Il a de l'expérience avec le système

Le système indique qu'il faut le faire

Pas d'évidence ?

Construire scénario d'échec

Expliquer pourquoi

35

Prochaine Questions

Est-ce qu'il sera capable de reconnaître la bonne action ?

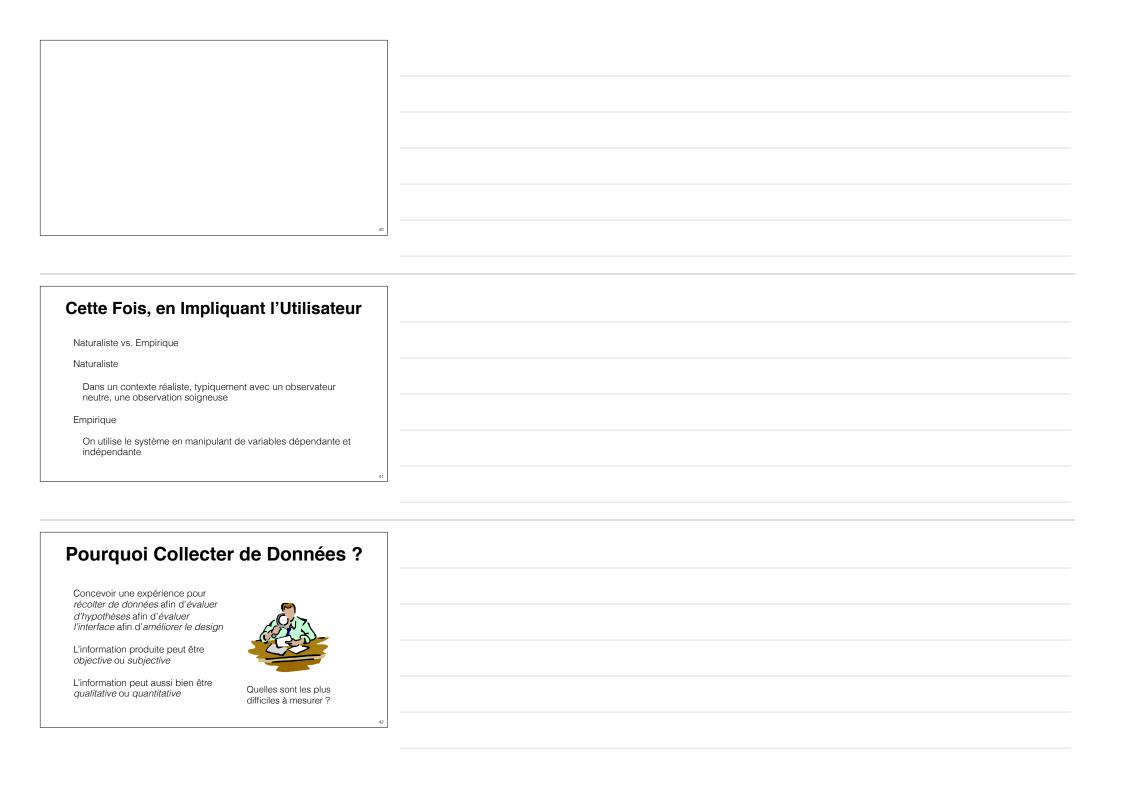
Evidence typique

Expérience

Dispositif visible (e.g. un bouton)

Représentation perceptible d'une action tel qu'un item de menu

Prochaine Questions	
Une fois trouvée, saura-t-il qu'elle est la bonne action pour l'effet souhaité ?	
Evidence typique	
Experience	
Item visuel (e.g. prompt) pour relier l'action à son effet	
Toute autre action ne semble pas être la bonne	
	37
Baralata A anti-	
Prochaine Question	
Comprendra-t-il le feedback après l'avoir effectué ?	
Evidence typique	
Expérience	
Reconnaître un lien entre réponse système et tâche de base	
neconnatte un terrette reponse systeme et tache de base	
	38



Piloter une Expérience

Identifier la tâche

Identifier les mesures de performance

Développer l'expérience

(Obtenir autorisation du bureau d'éthiques)

Recruter de participants

Faire passer l'expérience

Inspecter et analyser les données

Tirer de conclusions

43

La Tâche

Tâches étalonne — collectionnent données quantitatives

Tâches représentative — rajoutent de profondeur, aident à comprendre le processus

Quoi, pas Comment

Questions:

Dans le labo ou dans la nature ?

Validité — utilisateurs typiques ; tâches typiques ; environnement typique ?

Versions pilotes pour trouver de bogue dans l'expé

44

Tâches Étalonne

Spécifique, expliquer clairement dans un langage utilisateur

Exemple : gestion de mél

« Cherchez le message de Jean-Louis et répondez, "jeudi matin à 11h." »

L'utilisateur fait ces tâches sous plusieurs conditions ; on mesure la performance

Performance

Dépend la tâche

Mesures spécifiques, objectives

Exemples:

Vitesse (temps de réaction, complétion, ...)

Précision (taux d'erreurs, cibles ratées/atteintes, ...)

Production (combien de fichiers traités)

Score (points gagnés), ...

46

Variables

Indépendantes

Ce qu'on étudie, ce qu'on veut varié (*e.g.*, fonctionnalité de l'interface, dispositif interactif, technique de sélection, ...)

Dépendantes

Mesures de performance captées (e.g., temps, erreurs, ...)

47

"Contrôler" une Variable

Empêcher une variable d'avoir une influence systémique sur les résultats

Comment le faire :

Ne pas la permettre à varier (e.g., que des hommes)

Permettre-la à varier aléatoirement (*e.g.*, affecter de participants au groupes au hasard)

Contre-balancer la — la varier systématiquement

Le bon choix dépend les circonstances

Hypothèses

Ce qu'on pense se passera, la prédiction

Comment la variable dépendante répondra aux variables indépendantes

Hypothèse nul (H₀):

Qu'il n'y ait aucun effet

Données utilisées pour réfuter cette hypothèse

49

Exemple

L'utilisateur, fait-il cette opération plus vite avec un écran noir-et-blanc ou en avec un couleur ?

Indépendante : écran (couleur ou n/b)

Dépendante : temps d'exécuter la tâche (secondes)

Variables contrôlées : autant d'hommes que de femmes dans chaque groupe

Hypothèse : temps de complétion sera plus court avec l'écran couleur

H₀: Temps_{couleur} = Temps_{nb}

Problèmes?

50

Design de l'Expérience

Within subjects (mesures répétées)

Chaque participant fait chaque condition

Between subjects

Chaque participant fait qu'un seule condition

Within vs. Between Quels sont les avantages et inconvénients de chaque technique ? **Within Subjects** Plus efficace: Chaque participant produit plus de données Statistiques plus simples : Chaque personne et son propre contrôle Moins de participants Mais design potentiellement plus compliqué pour éviter d'effets **Between Subjects** Moins d'effet d'ordre Eviter les effets d'apprentissage, de fatigue Design, Analyse plus simple Plus facile de trouver de participants (une seule condition) Moins efficace

Participants

Ok, on a la tâche, les mesures, le design expérimental, etc.

On a des hypothèses

Pour avoir les données, il faut donc de participants

55

COPÉ & CPP

Comités d'éthiques de la recherche

Très important dans les pays anglo-saxons et dans d'autres pays européens

Audit toute recherche impliquant de participants humains

Assure la sécurité du participant (et donc le chercheur et le labo aussi)

Pas un audit de la science ; que de sureté et éthiques

56

Recruter de Participants

Genres:

Volontaires

Participants rémunérés

Etudiants (parfois rémunérés en crédits de cours)

Amis, famille, collègues, connaissances, ...

La publique en public (*e.g.*, observer des gens utilisants de bornes vélib)

Participants

Doivent coller aux utilisateurs (validité)

Motivation peut avoir une influence (€\$£ , importance de la recherche)

NB: l'Ethiques, COPÉ, principes de consent s'appliquent à tout participant, y compris amis, famille, sujets pilotes

58

Éthiques

Une expérience peut être difficle

Chaque participant doit donner son consent de passer l'expé

Il doit savoir ce que ça implique, à quoi s'attendre, les risques impliqués

Peut arrêter à n'importe quel moment sans danger ou pénalité

Chaque participant doit être traité avec de respect

59

Consentement

Pourquoi c'est important?

Des gens peuvent être sensible du processus

Au cas d'erreurs, le participant peut se sentir pas à la hauteur

Peut être mentalement ou physiquement épuisant

Quels sont les risques potentiels?

Avant l'expérience

Soyez prêt afin de ne pas faire perdre le temps du participant

Assurez que le participant sait que vous testez le logiciel, pas lui

Respectez la vie privée de l'utilisateur

Expliquez les procédures sans compromettant les résultats

Donner une formulaire de consent à signer

61

Pendent l'expérience

Assurez le confort du participant

La séance ne doit pas être trop longe

Maintenir une ambiance relaxe

Ne montre pas de mécontentement ou de colère

62

Après l'expérience

Décrivez comment la séance aidera à améliorer le système

Montrez au participant comment faire les tâches ratées

Assurez l'anonymat du participant (ne jamais identifiez la personne, ne montrez de photos, vidéos qu'avec l'accord explicite du participant)

Stockez les données anonymement, surement ; détruisez-les au bout du projet

Théorie d'attribution Une théorie sur pourquoi des gens pensent qu'ils ont réussi ou raté Expliquez comment des erreurs ou échecs ne sont pas de problèmes du participant, ce sont des parties de l'interface qu'il faut Collecte de Données **Collecte de Données** Méthodes, techniques Données objectives Données subjectives Données quantitatives Données qualitatives

Inspecteur

Faire de l'évaluation est comme être inspecteur

But : collectionner de l'évidence qui peut déterminer la validité des hypothèses

Evidence doit être :

Relevant

Diagnostique

Crédible

Corroborée



67

Données comme Evidence

Relevant

A propos d'hypothèses

e.g., mesurer le taux d'erreurs, donne-t-il une meilleur vue de si un système de contrôle aérienne gère les tâches utilisateur ?

Diagnostique

Données montrent sans ambiguité la réponse

e.g., demander les préférences de l'utilisateur, montre-t-il si le système marche mieux ? (peut-être)

68

Données comme Evidence

Credible

Les données sont-elles crédible ?

Assez nombreuses, recueillies avec soin

Corroboré

Y a-t-il plus qu'une source de données qui soutient les hypothèses ?

e.g., Précision et l'avis des utilisateurs montrent que le nouveau est plus facile à comprendre que l'ancien, mais le temps de complétion est plus lent

Conseils

Utiliser des données objectives et subjectives

Utiliser plusieurs mesures dans un genre

e.g., temps de réaction et précision

Quand possible, utiliser de mesures quantitives

70

Données à recueillir

Démographique

Qui est le participant, pour grouper ou pour corrélation aux autres mesures

e.g., gaucher ; âge ; langue maternelle ; jeux vidéos

Données quantitatives

Ce que vous mesurez (temps de réaction ; nombre de fois bâillé)

Donnée qualitatives

Description, observations

71

Préparer

Quelles données faut-il?

Dépend la tâche

Comment collecter les données ?

Naturelle, empirique, prédictive ?

Quels critères sont importants ?

Succès à la tâche ? Satisfaction ?

Quelles ressources sont disponible?

Collecter les Données Capture de la séance Observation, cahier Enregistrement audio/vidéo Interface instrumentée Logs d'utilisation

Journal d'incident critique

Think-aloud (penser à l'orale)

Journal utilisateur

Après la Séance

Entretiens, debriefing

- « Qu'est-ce que vous aimiez le mieux/pire ? »
- « Comment vous changerez ça ... ? »

Questionnaires, commentaires, ...

Classification d'événements dans la vidéo

74

Observer l'Utilisateur

Pas si facile ...

... mais un très bon outil pour obtenir de feedback sur l'interface

Regarder, écouter, apprendre pendent qu'une personne se sert de votre système

Vaut mieux le faire par un non-développeur

Observation

Directe
Dans la même pièce
Peut être intrusive
Utilisateur prend conscience de votre présence
Ephémère
Pas cher ; montage facile
Indirecte
Enregistrement vidéo
Moins d'intrusion
Caméras sur l'écran, visage, clavier
Archivée, mais cher à traiter

76

Environnment

Observations peuvent être :

Dans un laboratoire (d'utilisabilité ?)

Plus facile à contrôler

Peut demander à l'utilisateur de compléter une séries de tâches

Sur le terrain

Peut regarder les actions quotidiennes

Plus réaliste

Plus difficile à contrôler

77

Challenge

Dans une observation, on peut voir les actions utilisateurs, mais on ne sait pas ce qu'il pense

Peut utiliser un protocole verbale

Protocole Verbal

Think-aloud (penser à l'orale)

L'utilisateur décrit à l'orale ce qu'il pense en performant les tâches

Ce qu'il pense se passe

Pourquoi il fait une action

Ses buts

79

Think Aloud

Technique bien répandu, utile

Permet à mieux comprendre les pensés de l'utilisateur

Problèmes potentiels?

Peut être gênant, inconfortable pour l'utilisateur

Peut modifier la performance d'une tâche

80

L'ÉQUIPE

Une autre technique : co-discovery learning (interaction constructive)

Mettre participant en binôme

Utiliser think-aloud

Peut-être un expert et un débutant

Plus naturaliste (comme conversation), enlevant donc un peu d'inconfort de think-aloud traditionnel

Alternatif

Et si think-aloud est mal-adapté aux circonstances?

Protocole post-événement

L'utilisateur passe l'expérience, puis regarde une vidéo en décrivant ce qu'il pensait

Parfois difficile à s'en souvenir

Possibilité d'interprétation post-hoc

82

Rapport Historique

En observant l'utilisateur, comment capturer les événements de la séance pour l'analyse subséquente ?

83

Stylo sur Papier

Peut être lent

Possibilité de rater des choses

Facile et pas cher



Enregistrement

Audio et/ou vidéo

Marche très bien pour think-aloud

Difficile à relier à l'interface

Besoin potentiel de plusieurs caméras synchronisées

Bon, riche enregistrement de la séance

Intrusif

Difficile à transcrire et analyser

85

Demo Usability Test

for readers of



Rev. 1.1 / February 3, 2010 © 2010 Steve Krug www.rocketsurgerymadeeasy.com





Laboratoire d'Utilisabilité

_

Salle d'Observation

Grand champ de vision, glace unidirectionnel, isolation de lumière et son

Portes situées tel que le participant ne peut pas les voire en entrant dans la salle d'observation



88

Salle d'Observation

Trois écrans pour voir le participant, l'écran du participant, et les deux à la fois

Confortable pour plusieurs observateurs

DVD-R pour enregistrer la séance



89

Salle du Participant

Se ressemble à un bureau norn

Caméra haute-résolution, contro à distance, placée discrètemer dans le coin

Micro



Logs

Modifier le logiciel pour enregistrer les actions utilisateurs

t, x, y, genre-d'événement, ...

Synchronisé à la vidéo

Logiciels commercial disponible

Deux problèmes principaux :

Très bas niveau

Beaucoup de données ; besoin d'outils d'analyse

91

Problèmes

Si l'utilisateur s'enlise sur une tâche?

Peut demander:

- « Qu'est-ce que vous essayez de faire ? »
- « Qu'est-ce qui vous a fait pensez ... ? »
- « Comment voulez-vous faire ça? »
- « Qu'est-ce qui vous le fera plus facile à faire ? »

Peut-être donner un indice

92

Données subjectives

Dans la longue duré, satisfaction est un facteur très important

Il est donc très important de savoir ce que des gens préfèrent

Méthodes Questionnaires Entretiens Expos hot-line ...

Questionnaires

Cher à préparer, mais facile à passer

Orale ou écrit

Orale: peut suivre avec autres questions

Orale : mais coûte plus cher, prend du temps

Formulaires donnent données plutôt quantitative

95

Questionnaires

Points importants:

Limités par les questions posées

Faut établir le but du questionnaire

Ne pas poser de questions que vous n'utiliserez pas

Qui est la publique?

Comment livrer et récupérer le questionnaire ?

Sujet du Questionnaire	
Peut collecter de données démographiques et données sur l'interface impliquée	
Données démographiques :	
Âge, sexe	
Expertise sur les tâches impliquées	
Motiviation	
Fréquence d'utilisation	
Niveau d'éducation	
	97
Données sur l'interface	
Ecran	
Design	
Terminologie	
Capacités	
Apprentissage	
Impression globale	
	98
Format de Questionnaire	
Fermé :	
Réponses restreint	
Typiquement facile à quantifier	
Plusieurs formes possibles	
r iusieurs iurities pussibies	
	99

Format Fermé

Echelle Likert

Typiquement 5, 7 ou 9 choix

Plus que ça, trop difficile à distinguer

Nombre impaire permet un choix neutre

Les caractères sur l'écran était facile à lire :

Difficile à lire

Facile à lire

12 3 4 5 6 7

Autres options

Boîtes à crocher

Réponses ordonnées

Format Fermé

Avantages
Peut clarifier alternatifs
Facile à quantifier
Peut éliminer réponses inutiles

Désavantages Obligé de couvrir toute option Toute réponse également probable Pas de réponses non-prévues

Format Ouvert

Solliciter avis non-prévu

Mieux adapté aux données subjectives, difficile à analyser rigoreusement

Peut donner des idées sur le design

"Pouvez-vous suggérer d'améliorations à cette interface ?"

Points Importants

Spécificité de questions

"Avez-vous d'ordinateur ?"

Langage

Eviter le jargon, la terminologie

Clarité

"Le système, était-il efficace?"

Questions tendancieuses

Points Importants

Biais de prestige

Des gens répondent selon comment ils veulent être perçu

Questions embarrassantes

"Où est-ce que vous ne vous pouvez pas débrouiller ?"

Questions hypothétique

"Effet halo"

Quand une dimension à un effet sur un autre (intelligence/style)

. . .

Déploiement	
Délibérer questions internement	
Faire passer une version pilote	
Faire passer la version finale	
Si possible, utiliser une version numérique	
108	5
]
107	,